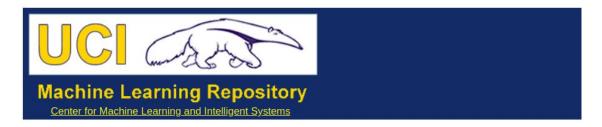
REGRESSÃO

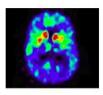
Cada problema tem o seu domínio próprio e suas características. Estas características se refletem no conjunto de dados deste domínio. Para exemplificar, vamos supor que queiramos criar um sistema de regressão para predizer o valor de UPDRS baseado nos dados fornecidos. ("Unified Parkinson's Disease Rating Scale (UPDRS) is the most widely used measure to assess motor symptoms and signs in Parkinson's disease (PD"). (https://www.hindawi.com/journals/pd/2012/719167/).



Parkinsons Telemonitoring Data Set

Download: Data Folder, Data Set Description

Abstract: Oxford Parkinson's Disease Telemonitoring Dataset



Data Set Characteristics:	Multivariate	Number of Instances:	5875	Area:	Life
Attribute Characteristics:	Integer, Real	Number of Attributes:	26	Date Donated	2009-10-29
Associated Tasks:	Regression	Missing Values?	N/A	Number of Web Hits:	111555

https://archive.ics.uci.edu/ml/datasets/Parkinsons+Telemonitoring

O segundo dataset é o descrito abaixo:



Physicochemical Properties of Protein Tertiary Structure Data Set

Download: Data Folder, Data Set Description

Abstract: This is a data set of Physicochemical Properties of Protein Tertiary Structure. The data set is taken from CASP 5-9. There are 45730 decoys and size varying from 0 to 21 armstrong.

Data Set Characteristics:	Multivariate	Number of Instances:	45730	Area:	Life
Attribute Characteristics:	Real	Number of Attributes:	9	Date Donated	2013-03-31
Associated Tasks:	Regression	Missing Values?	N/A	Number of Web Hits:	37712

https://archive.ics.uci.edu/ml/datasets/Physicochemical+Properties+of+Protein+Tertiary+Structure#

Problema a ser resolvido

Nesta caso, o problema é construir um componente de machine learning que seja capaz de estimar os valores de saída baseado nos valores de entrada.

Solução do Problema

As principais métricas para regressão são:

MSE (https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html) R2 (https://scikit-learn.org/stable/modules/generated/sklearn.metrics.r2 score.html)

Como avaliar estas métricas?

	MSE	R2
Melhor valor	0	1

Tabela 2: Métricas para Regressão.

Escolha do Algoritmo de Regressão

Testamos vários algoritmos de regressão e verificamos qual deles tem o melhor R2 e o menor MSE.

Fazendo a codificação em Python 3.6 temos:

```
#REGRESSAO
        import pandas as pd
3
        from sklearn import linear model
4
        from sklearn.ensemble import RandomForestRegressor
5
        from sklearn.metrics import mean squared error, r2 score
6
        from sklearn.model selection import train test split, KFold
7
        from sklearn.neural network import MLPClassifier, MLPRegressor
8
        from sklearn.svm import SVR
9
        from sklearn import ensemble
        from sklearn.decomposition import PCA
        from sklearn.preprocessing import scale
11
12
13
        df = pd.read csv('parkinsons updrs.csv')
14
        cols = df.columns.tolist()
15
        motor UPDRS = cols.pop(4)
        total UPDRS = cols.pop(4)
17
        cols.append(motor UPDRS)
18
        cols.append(total UPDRS)
19
        df = df[cols]
        df = df.dropna()
28
       y1 = df['motor_UPDRS'].values
X1 = df.loc[:,'Jitter(%)':'PPE'].values
21
22
23
24
        df = pd.read csv('CASP.csv')
25
        df = df.dropna()
        y = df['RMSD']
26
27
        X = df.loc[:,'F1':'F9']
28
29
38 🔴
        X = scale(X)
31
        pca = PCA(n components=6)
        Xpca = pca.fit transform(X)
        X = Xpca
34
35
36
        nfolds = 10
37
        kf = KFold(n splits=nfolds, shuffle=True)
        params = {'n estimators': 500, 'max depth': 4, 'min samples split': 2,
38
                   'learning_rate': 0.0001, 'loss': 'ls'}
39
40
        regress = {"Boost": ensemble.GradientBoostingRegressor(**params),
41
                    "RF": RandomForestRegressor(n_estimators=1000,n_jobs=-1),
42
                   "LINR": linear model.SGDRegressor(max_iter=500, tol=1e-6),
43
                   "MLP": MLPRegressor(hidden layer sizes=(100 ), max iter=500),
44
45
                    "svr_rbf": SVR(kernel='rbf', C=le3, gamma=0.1),
                    'svr_li':SVR(kernel='linear', C=le3),
46
47
                    'svr poly':SVR(kernel='poly', C=1e3, degree=2)
48
                   }
49
50
        for train index, test index in kf.split(X):
53
            X_train, X_test = X[train_index], X[test_index]
            y train, y test = y[train index], y[test index]
            for name, regr in regress.items():
56
57
                # Train the model using the training sets
58
                regr.fit(X train, y train)
                # Make predictions using the testing set
60
                y_pred = regr.predict(X_test)
61
                print(name)
                print("MSE: %.2f" % mean squared error(y test, y pred))
62
63
                print('R2 score: %.2f, 1 is the best! ' % r2 score(y test, y pred))
```

Um fragmento da saída da máquina de regressão é:

Boost
MSE: 36.39
R2 score: 0.03, 1 is the best!
RF
MSE: 14.89
R2 score: 0.60, 1 is the best!
LINR
MSE: 28.06
R2 score: 0.25, 1 is the best!
MLP
MSE: 21.39
R2 score: 0.43, 1 is the best!
svr_rbf
MSE: 23.21
R2 score: 0.38, 1 is the best!

Pode-se observar que para cada algoritmo as métricas são diferentes.

Para realizarmos o Deploy, fazemos exatamente como foi feito no processo de classificação.

Exercício - Criar um objeto de predição utilizando os mesmos datasets porém, com redução de dimensionalidade utilizando PCA e MDS. Compare os resultados.

https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html https://scikit-learn.org/stable/modules/generated/sklearn.manifold.MDS.html